

Préparation à l'agrégation externe de Sciences Sociales

Statistique inférentielle - Estimateurs et Intervalles de confiance

2023-2024

Exercice 1

1. (a) X suit une loi binômiale de paramètres 925 et 0,32.
- (b) D'après le théorème central limite, la loi de X peut être approchée par une loi normale de paramètres $925 \times 0,32$ et $925 \times 0,32 \times 0,68$.
- (c) Si l'on vous donne seulement Φ la fonction de répartition d'une loi gaussienne centrée réduite $\mathcal{N}(0, 1)$ et en utilisant l'approximation précédente¹,

$$\begin{aligned} & \mathbf{P}(0,30 \times 925 \leq X \leq 0,40 \times 925) \\ & \approx \Phi\left(\frac{0,30 \times 925 - 0,32 \times 925}{\sqrt{925 \times 0,32 \times 0,68}}\right) - \Phi\left(\frac{0,40 \times 925 - 0,32 \times 925}{\sqrt{925 \times 0,32 \times 0,68}}\right) \\ & \approx 0,903 \text{ à } 10^{-3} \text{ près.} \end{aligned}$$

2. (a) L'estimation de son score est de $\frac{46}{200} = 23\%$.
Appelons \hat{s} l'estimateur associé, qui compte le nombre de voix en faveur de la tête de liste et le divise par 200 soit

$$\hat{s} = \frac{\sum_{i=1}^{200} X_i}{200}$$

où les X_i sont indépendants et suivent la loi de X . Alors $200\hat{s}$ suit une loi binômiale de paramètres 200 et s , où s est le vrai score.

- (b) On approxime cette loi par une loi normale de paramètres $200s = \mathbf{E}(\hat{s})$ et $200s(1-s) = \mathbf{Var}(\hat{s})$.
Donc, avec une probabilité au moins égale à 95%, on a

$$|200\hat{s} - 200s| \leq 1,96 \times \sqrt{200s(1-s)} \leq 1,96 \times \sqrt{50},$$

car on a $p(1-p) \leq 1/4$ quelque soit p compris entre 0 et 1. Soit :

$$|\hat{s} - s| \leq 1,96 \times \sqrt{\frac{s(1-s)}{200}} \leq 1,96 \times \sqrt{\frac{1}{4 \times 200}} \approx 0,069$$

D'où l'intervalle de confiance au niveau de confiance 95% pour le score :

$$s \in [\hat{s} - 0,07; \hat{s} + 0,07] = [0,16; 0,30] = [16\%; 30\%].$$

Exercice 2

On appelle X_1, \dots, X_{n_1} les variables aléatoires observées dans le premier échantillon, la variable X_i prenant la valeur 1 si le i -ème foyer possède le bien et 0 sinon, et X'_1, \dots, X'_{n_2} les variables aléatoires construites de la même façon à partir des observations réalisées dans le deuxième échantillon.

1. Avec certaines calculatrices vous pouvez directement calculer $\mathbf{P}(0,30 \times 925 \leq X \leq 0,40 \times 925)$, avec $X \sim \mathcal{N}(925 \times 0,32, 925 \times 0,32 \times 0,68)$, vérifiez si c'est votre cas!

1. Les observations $X_1, \dots, X_{n_1}, X'_1, \dots, X'_{n_2}$ sont indépendantes et de même loi de Bernoulli de paramètre p . La somme

$$S_1 = \sum_{k=1}^{n_1} X_k$$

suit donc une loi binomiale de paramètres n_1 et p , tandis que la somme

$$S_2 = \sum_{k=1}^{n_2} X'_k$$

suit donc une loi binomiale de paramètres n_2 et p . Leur espérances sont

$$E(S_1) = n_1 p \text{ et } E(S_2) = n_2 p$$

et leur variances

$$V(S_1) = n_1 p(1-p) \text{ et } V(S_2) = n_2 p(1-p).$$

2. $E(F_1) = \frac{1}{n_1} E(S_1) = p$ et $E(F_2) = \frac{1}{n_2} E(S_2)$.
 $V(F_1) = \frac{1}{n_1^2} V(S_1) = \frac{p(1-p)}{n_1}$ et $V(F_2) = \frac{1}{n_2^2} V(S_2) = \frac{p(1-p)}{n_2}$.
3. F_1 et F_2 sont des estimateurs car ils sont définis uniquement en fonction des observations X_i et X'_i et peuvent être calculés à l'aide de ces observations sans connaître p . Le fait qu'ils soient sans biais résulte de la question précédente puisque l'on a vu que leurs espérances étaient toutes deux égales à p .
4. $E(G) = \frac{E(F_1) + E(F_2)}{2} = p$. En tant que fonctionnelle d'estimateurs de p , G est un estimateur de p ; on vient de plus de voir qu'il est sans biais.
5. F_1 et F_2 sont indépendantes, donc

$$\begin{aligned} V(G) &= \frac{1}{4} (V(F_1) + V(F_2)) \\ &= \frac{1}{4} \left(\frac{p(1-p)}{n_1} + \frac{p(1-p)}{n_2} \right) \\ &= \frac{1}{4} \left(\frac{1}{n_1} + \frac{1}{n_2} \right) p(1-p) \end{aligned}$$

6. G est obtenu en faisant la moyenne des deux estimateurs F_1 et F_2 , ce qui revient à leur donner la même importance. Pourtant, F_1 est obtenue à partir d'un échantillon plus grand que F_2 et devrait à ce titre être davantage pondérée pour obtenir un estimateur de meilleure qualité (c'est le sens de la question suivante!). Lorsque l'on calcule la moyenne de F_1 et F_2 , on prend certes en compte plus d'information que lors du calcul de F_1 , mais on donne à l'information issue du deuxième échantillon un poids démesuré. On s'attend donc à ce que G soit meilleur que F_1 (et donc que F_2) lorsque n_1 et n_2 ne sont pas trop éloignés : c'est la zone dans laquelle l'effet positif de l'ajout d'information prévaut. On s'attend par contre à perdre en précision du fait de la moyennisation avec F_2 lorsque F_1 est beaucoup plus précis que F_2 , c'est-à-dire lorsque n_1 est bien plus grand que n_2 . Le tout est de quantifier le seuil auquel ce phénomène arrive... La qualité d'un estimateur se mesure (pour nous) à l'aide de son risque quadratique. G étant sans biais en tant qu'estimateur de p , on a

$$\text{RQ}(G, p) = V(G) = \frac{1}{4} \left(\frac{1}{n_1} + \frac{1}{n_2} \right) p(1-p)$$

Par ailleurs, F_1 et F_2 sont des estimateurs sans biais de p , donc leur risque quadratique est une fois encore égal à leur variance; comme $n_1 > n_2$, le risque quadratique le plus bas est celui de

F_1 d'après la question 2. G est donc un meilleur estimateur que F_1 et F_2 si et seulement s'il est meilleur que F_1 , c'est-à-dire si

$$\text{RQ}(G, p) < \text{RQ}(F_1, p).$$

Alors,

$$\begin{aligned} \text{RQ}(G, p) < \text{RQ}(F_1, p) &\Leftrightarrow \frac{1}{4} \left(\frac{1}{n_1} + \frac{1}{n_2} \right) p(1-p) < \frac{1}{n_1} p(1-p) \\ &\Leftrightarrow \frac{1}{4} \left(\frac{1}{n_1} + \frac{1}{n_2} \right) < \frac{1}{n_1} \\ &\Leftrightarrow \frac{1}{4} \left(1 + \frac{n_1}{n_2} \right) < 1 \\ &\Leftrightarrow 1 + \frac{n_1}{n_2} < 4 \\ &\Leftrightarrow \frac{n_1}{n_2} < 3. \end{aligned}$$

G est donc meilleur que F_1 et F_2 si et seulement si $n_1 < 3n_2$.

7. L'estimateur $uF_1 + vF_2$ est sans biais si et seulement si $u + v = 1$, et sa variance est alors égale à $u^2 \frac{p(1-p)}{n_1} + (1-u)^2 \frac{p(1-p)}{n_2}$.

Notons $f(u) = \frac{u^2}{n_1} + \frac{(1-u)^2}{n_2} = u^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right) - \frac{2u}{n_2} + \frac{1}{n_2}$ pour tout réel u . f est une fonction polynômiale du second degré, et son coefficient dominant est strictement positif, donc elle admet un minimum pour $u = u_0 = \frac{n_1}{n_1 + n_2}$. En effet sa dérivée $f'(u) = \frac{2u}{n_1} + \frac{-2(1-u)}{n_2}$ s'annule si et seulement si

$$\frac{2u}{n_1} + \frac{-2(1-u)}{n_2} = 0 \Leftrightarrow \frac{u}{n_1} = \frac{1-u}{n_2} \Leftrightarrow u = u_0$$

Donc le meilleur estimateur non-biaisé de la forme $uF_1 + vF_2$ est

$$\frac{n_1}{n_1 + n_2} F_1 + \frac{n_2}{n_1 + n_2} F_2.$$